

Projet : Comparaison des Chronologies d'Événements Sportifs

Avancement de la partie TAL

Traitement Automatique du Langage Naturel

Étudiant : Abdelkerim Hamit Mahamat

Formation : Master 1 Informatique – ASI

Université : Université de Caen Normandie

Contexte

Dans le cadre du projet *Comparaison des Chronologies d'Événements Sportifs sur les Réseaux Sociaux*, ma contribution porte sur la partie **Traitement Automatique du Langage Naturel**.

L'objectif principal est d'extraire automatiquement des événements sportifs à partir de publications issues des réseaux sociaux afin de construire une **chronologie sociale** du match.

Idée principale : transformer des textes bruts issus des réseaux sociaux en événements structurés exploitables pour l'analyse.

1 Exploration des données

Nous avons travaillé sur un fichier JSON contenant des publications et commentaires liés à un match de football.

Les informations principales exploitées sont :

- le titre de la publication ;
- la date de publication ;
- le nombre de commentaires ;
- les informations temporelles liées au match.

Après analyse du fichier, nous avons observé :

- 200 publications récupérées ;
- 46 416 commentaires analysés ;
- 1 228 commentaires situés dans les fenêtres temporelles du match ;
- un taux de correspondance de 2,65 %.

Cette étape a permis d'identifier un point important : les données issues des réseaux sociaux sont riches mais fortement bruitées.

2 Prétraitement des textes

Avant toute analyse TAL, les titres des publications ont été nettoyés.

Les opérations réalisées sont :

- passage en minuscules ;
- suppression de la ponctuation inutile ;
- normalisation des répétitions de caractères ;
- conservation des éléments utiles comme les scores.

Exemple :

G00000AL Liverpool !!!

↓

goal liverpool

Cette étape permet de réduire le bruit linguistique et d'obtenir des textes plus simples à analyser.

3 Détection d'événements sportifs

Une première méthode par règles a été développée à l'aide d'expressions régulières.

Les événements détectés sont :

- **FIN_MATCH** ;
- **MATCH_THREAD** ;
- **VAR** ;
- **PENALTY** ;
- **BUT** ;
- **CARTON_ROUGE** ;
- **AUTRE**.

Exemples

Texte détecté	Événement associé
Post Match Thread	FIN_MATCH
Match Thread	MATCH_THREAD
VAR Review	VAR
Penalty	PENALTY
Goal / scored / equalizer	BUT

Cette méthode est simple, rapide et surtout interprétable.

4 Extraction automatique des scores

Une fonction a été ajoutée afin d'extraire automatiquement les scores présents dans les titres.

Exemple :

Galatasaray 1-0 Liverpool

↓

Score extrait : 1-0

Cette extraction permet d'enrichir les événements détectés avec une information quantitative.

5 Construction d'une chronologie sociale

Chaque publication a été associée à une minute relative au début du match.

Les publications ont ensuite été classées en trois catégories :

- **AVANT_MATCH**;
- **PENDANT_MATCH**;
- **APRES_MATCH**.

Cette étape permet de construire une première **timeline sociale** à partir des réactions observées sur les réseaux sociaux.

La timeline sociale permet d'observer à quel moment les discussions apparaissent par rapport au déroulement du match.

6 Représentation TF-IDF

Les titres ont ensuite été transformés en vecteurs numériques à l'aide de la méthode **TF-IDF**.

Cette méthode permet d'attribuer un poids aux mots selon leur importance dans le corpus.

- un mot fréquent dans un titre est important ;
- un mot rare dans le corpus est plus discriminant ;
- les textes peuvent ensuite être utilisés par un modèle de Machine Learning.

Cette étape marque le passage d'une approche par règles à une approche statistique.

7 Classification supervisée

Une régression logistique a été entraînée pour prédire automatiquement les événements.

Le pipeline utilisé est le suivant :



```
graph TD; A[Titres des posts] --> B[TF-IDF]; B --> C[Régression logistique]; C --> D[Prédiction de l'événement];
```

Titres des posts
↓
TF-IDF
↓
Régression logistique
↓
Prédiction de l'événement

Les performances ont été évaluées à l'aide :

- de l'accuracy ;
- du rapport de classification ;
- de la matrice de confusion.

8 Analyse et amélioration

L'analyse du modèle a permis d'identifier certaines erreurs.

Par exemple, la détection initiale de **VAR** reconnaissait aussi des mots contenant la séquence **var**, comme **Vardy**. Cette erreur a été corrigée grâce à l'utilisation d'expressions régulières plus précises.

Les règles ont aussi été enrichies afin de mieux détecter les buts avec des termes comme :

- goal ;
- scored ;
- equalizer ;
- winner ;
- strike.

Cette étape montre une démarche itérative :

analyse des erreurs → correction des règles → réentraînement du modèle

9 Visualisations réalisées

Plusieurs visualisations ont été produites :

- distribution des événements détectés ;
- timeline sociale ;
- activité sociale autour du match ;
- activité moyenne par type d'événement.

Ces visualisations permettent d'analyser le lien entre les événements détectés et les réactions des utilisateurs.

10 Limites observées

Plusieurs limites ont été identifiées :

- corpus relativement réduit ;
- bruit important dans les données sociales ;
- annotations automatiques imparfaites ;
- événements parfois exprimés de manière implicite ;
- filtrage lexical encore améliorable.

Ces limites ouvrent la voie à des améliorations futures.

11 Perspectives

Les prochaines améliorations possibles sont :

- annoter manuellement une partie du corpus ;
- utiliser des modèles plus avancés comme BERT ou CamemBERT ;
- détecter les émotions des supporters ;
- comparer la chronologie sociale avec une chronologie officielle détaillée ;
- intégrer plusieurs réseaux sociaux.

Conclusion

La partie TAL permet déjà :

- d'extraire automatiquement des événements sportifs ;
- de construire une chronologie sociale ;
- d'étudier l'activité des utilisateurs autour du match ;
- de relier les techniques de TAL aux objectifs globaux du projet.

Contribution principale :

Transformer des textes sociaux bruités en événements sportifs structurés.