



UNIVERSITÉ
CAEN
NORMANDIE

RAPPORT DE PROJET

Comparison of Sport Event Timelines from Social Media

Analyse automatique des événements sportifs
à partir des réseaux sociaux

Membres du groupe

Étudiant : Britel Mohammed Yassine
Étudiant : Abdelkerim Hamit Mahamat
Étudiant : Lee Taiwen

Encadrement

Pr. Marc Spaniol
Pr. Alexandre Niveau

Année universitaire : 2025 – 2026

Projet réalisé dans le cadre du module de Traitement Automatique du Langage Naturel
Master 1 – Algorithmique et Systèmes Intelligents

Sommaire

Table des matières

Résumé	1
1 Introduction générale	2
1.1 Problématique	2
1.2 Objectifs du projet	2
2 Organisation générale du rapport	4
2.1 Partie I : Analyse des données	4
2.2 Partie II : Traitement Automatique du Langage naturel	4
2.3 Partie III : Analyse de sentiment	4
I Analyse des données	5
3 Données utilisées	6
3.1 Sources de données	6
3.2 Corpus centré sur Galatasaray contre Liverpool	6
3.3 Corpus multi-match	6
4 Méthodologie proposée	8
4.1 Vue générale du pipeline	8
4.2 Nettoyage des données	8
4.3 Association temporelle	8
5 Analyse du match Galatasaray contre Liverpool	9
5.1 Volume des réactions Reddit	9
5.2 Mots-clés d'événements	10
5.3 Langues détectées	10
5.4 Entités mentionnées	11
6 Analyse multi-match	12
6.1 Objectif de l'extension multi-match	12

6.2	Volumes observés	12
6.3	Analyse des plateformes	13
II	Traitement Automatique du Langage naturel	14
7	Contribution TAL : extraction, structuration et classification des événements sportifs	15
7.1	Rôle de la partie TAL	15
7.2	Chargement et exploration des données	15
7.3	Filtrage des publications pertinentes	15
7.4	Nettoyage TAL des titres	16
7.5	Détection des événements par règles	16
7.6	Extraction automatique des scores	16
7.7	Construction du tableau final TAL	17
7.8	Distribution initiale des événements détectés	17
7.9	Construction de la timeline sociale	18
7.10	Filtrage temporel de la timeline	18
7.11	Activité sociale associée aux événements	19
7.12	Vectorisation TF-IDF	19
7.13	Classification supervisée des événements	19
7.14	Amélioration des règles et des labels	19
7.15	Comparaison des versions du modèle	20
7.16	Analyse de sentiment appliquée aux titres	20
7.17	Analyse de sentiment appliquée aux commentaires	21
7.18	Limites de la contribution TAL	21
7.19	Apport global de la contribution TAL	21
III	Analyse de sentiment et détection automatique d'événements	22
8	Analyse de sentiment et détection automatique d'événements	23
8.1	Comparaison des timelines	23
8.1.1	Timeline officielle	23
8.1.2	Timeline sociale	23
8.1.3	Timeline médiatique	23
8.2	Événements du match Galatasaray vs Liverpool et impact émotionnel	23
8.3	Objectif de l'analyse de sentiment	24
8.4	Modèle utilisé	26
8.5	Agrégation temporelle	26
8.6	Classification des fenêtres événementielles	26
8.7	Visualisation de la détection d'événements	27
9	Discussion générale	28

9.1	Forces du projet	28
9.2	Limites	28
9.3	Perspectives	28
9.4	Accès au code source et aux fichiers du projet	28
10	Conclusion	29

Résumé

Ce projet porte sur la comparaison de chronologies d'événements sportifs à partir de données issues des réseaux sociaux et des médias numériques. L'objectif principal est de déterminer dans quelle mesure les réactions publiées en ligne permettent de reconstruire, d'analyser et de comparer les moments importants d'un match de football.

Le travail réalisé combine plusieurs contributions complémentaires. Une première partie étudie le match Galatasaray contre Liverpool à partir de commentaires Reddit, d'articles de presse et de résultats issus d'une chaîne de traitement automatique du langage naturel. Une deuxième partie porte sur la contribution TAL, qui transforme les textes collectés en événements sportifs structurés. Une troisième partie analyse le sentiment et l'évolution émotionnelle des commentaires autour des événements du match.

Les résultats montrent que les réseaux sociaux produisent une réaction rapide, émotionnelle et fortement liée au déroulement du match, tandis que les médias fournissent une information plus structurée. Le projet met ainsi en évidence la complémentarité entre les sources sociales, médiatiques et officielles pour reconstruire une chronologie sportive enrichie.

Mots-clés : réseaux sociaux, football, chronologie sportive, TAL, analyse de sentiment, Reddit, médias, détection d'événements.

1. Introduction générale

Les événements sportifs occupent une place importante dans les échanges numériques contemporains. Lorsqu'un match de football se déroule, les spectateurs ne se contentent plus de regarder la rencontre : ils commentent, réagissent, débattent et interprètent chaque moment important sur les réseaux sociaux.

Ces réactions constituent une masse importante de données textuelles, souvent bruitées, mais très riches sur le plan temporel, émotionnel et informationnel. Dans ce contexte, les réseaux sociaux peuvent être considérés comme des capteurs collectifs d'événements.

Le projet *Comparison of Sport Event Timelines from Social Media* vise à comparer plusieurs types de chronologies : la chronologie officielle des événements sportifs, la chronologie des réactions sociales et la chronologie médiatique produite par les articles de presse.

1.1 Problématique

La problématique centrale de ce projet est la suivante :

Comment reconstruire, analyser et comparer automatiquement des chronologies d'événements sportifs à partir de données issues des réseaux sociaux et des médias numériques ?

1.2 Objectifs du projet

Les objectifs du projet sont les suivants :

- collecter et organiser des données issues des réseaux sociaux et des médias ;
- analyser les réactions autour du match Galatasaray contre Liverpool ;
- élargir l'étude à plusieurs matchs et plateformes ;
- détecter automatiquement les événements sportifs dans les textes ;
- analyser le sentiment et l'évolution émotionnelle des commentaires ;
- comparer les timelines sociales, médiatiques et officielles ;

- proposer une lecture critique des résultats obtenus.

2. Organisation générale du rapport

Le rapport est organisé en trois grandes parties complémentaires. Cette structure permet de présenter le projet de manière claire, progressive et cohérente.

La première partie est consacrée à l'**analyse des données**. Elle présente les sources utilisées, le corpus centré sur le match Galatasaray contre Liverpool, l'analyse multi-match et les principales observations issues des données collectées.

La deuxième partie est consacrée au **Traitement Automatique du Langage naturel**. Elle explique comment les textes sont nettoyés, structurés, transformés en événements sportifs, puis exploités pour construire une chronologie sociale du match.

La troisième partie est consacrée à l'**analyse de sentiment**. Elle ajoute une dimension émotionnelle à l'étude en analysant la tonalité des commentaires et leur évolution temporelle autour des événements sportifs.

2.1 Partie I : Analyse des données

Cette première partie présente les données utilisées dans le projet. Elle décrit les sources exploitées, notamment Reddit, les médias numériques et les timelines officielles.

2.2 Partie II : Traitement Automatique du Langage naturel

La deuxième partie présente la contribution TAL du projet. Elle explique comment les textes collectés sont transformés en données structurées.

2.3 Partie III : Analyse de sentiment

La troisième partie est consacrée à l'analyse de sentiment. Elle cherche à comprendre comment les supporters réagissent émotionnellement aux événements du match.

Première partie

Analyse des données

3. Données utilisées

3.1 Sources de données

Le projet exploite plusieurs catégories de données :

- des commentaires Reddit associés aux périodes d'un match ;
- des articles de presse collectés à partir de sources médiatiques ;
- des fichiers de configuration décrivant les matchs, les équipes, les joueurs et les événements officiels ;
- des résultats issus de la chaîne TAL.

3.2 Corpus centré sur Galatasaray contre Liverpool

Le premier corpus étudié concerne le match Galatasaray contre Liverpool. Les données utilisées comprennent notamment :

- 200 publications analysées ;
- 46 416 commentaires parcourus ;
- 1 228 commentaires associés à des fenêtres temporelles du match ;
- 100 articles de presse ;
- 90 lignes de résultats issues de la partie TAL.

Le taux de commentaires effectivement associés aux fenêtres du match est d'environ 2,65 pour cent. Ce taux montre que la quantité brute de commentaires n'est pas suffisante : il faut filtrer, nettoyer et relier les messages aux périodes pertinentes.

3.3 Corpus multi-match

Une seconde partie du projet élargit l'analyse à cinq matchs. Le corpus multi-match contient :


- 5 matchs configurés ;

- 400 articles de presse;
- 99 publications sociales;
- 111 commentaires récupérés;
- des timelines officielles pour comparer les événements détectés.

4. Méthodologie proposée

4.1 Vue générale du pipeline

La méthodologie générale du projet repose sur une chaîne de traitement complète allant des données brutes jusqu'à la comparaison des timelines.



4.2 Nettoyage des données

Les données issues des réseaux sociaux sont fortement bruitées. Elles contiennent des liens, des caractères spéciaux, des abréviations, des fautes, des emojis et parfois plusieurs langues dans un même fil de discussion.

4.3 Association temporelle

Les commentaires sont associés à des fenêtres temporelles telles que 00 :00, 15 :00, 30 :00, 45 :00, 60 :00, 75 :00 et 90 :00. Cette association permet de relier les réactions sociales aux moments du match.

5. Analyse du match Galatasaray contre Liverpool

5.1 Volume des réactions Reddit




FIGURE 5.1 – Distribution des scores des commentaires Reddit




FIGURE 5.2 – Activité Reddit par fenêtre de référence du match

Les périodes les plus actives sont les suivantes :

- 00 :00 : 920 commentaires ;
- 15 :00 : 388 commentaires ;
- 30 :00 : 257 commentaires ;
- 45 :00 : 162 commentaires ;

- **60 :00** : 106 commentaires ;
- **75 :00** : 90 commentaires ;
- **90 :00** : 71 commentaires.

5.2 Mots-clés d'événements




FIGURE 5.3 – Comparaison des mots-clés les plus fréquents sur Reddit et dans les médias

L'analyse des mots-clés montre que les termes liés au but sont les plus fréquents. Les mots liés à la VAR, au hors-jeu, au penalty ou à l'arbitrage apparaissent également, mais avec des volumes plus faibles.

5.3 Langues détectées

La distribution observée est la suivante :

- **Anglais** : 1035 commentaires ;
- **Turc** : 106 commentaires ;
- **Autre** : 85 commentaires ;
- **Français** : 2 commentaires.

5.4 Entités mentionnées




FIGURE 5.4 – Comparaison des entités les plus fréquentes sur Reddit et dans les médias

L'analyse des entités montre que les noms des deux équipes dominent très fortement. Liverpool et Galatasaray sont mentionnés dans la majorité des contenus médiatiques et sociaux.

6. Analyse multi-match

6.1 Objectif de l'extension multi-match

L'analyse multi-match permet de dépasser le cadre d'une seule rencontre. Les cinq matchs étudiés sont notamment :

- Atlético Madrid contre Inter Milan ;
- Real Madrid contre Manchester City ;
- Arsenal contre PSG ;
- Barcelona contre Bayer Leverkusen ;
- Liverpool contre Galatasaray.

6.2 Volumes observés




FIGURE 6.1 – Volume de commentaires par période du match pour les cinq rencontres étudiées

Les volumes observés par match sont les suivants :

- **Atlético Madrid vs Inter Milan** : 100 articles, 19 posts sociaux, 0 commentaire ;

- **Real Madrid vs Manchester City** : 100 articles, 18 posts sociaux, 106 commentaires ;
- **Arsenal vs PSG** : 100 articles, 19 posts sociaux, 0 commentaire ;
- **Barcelona vs Bayer Leverkusen** : 0 article, 25 posts sociaux, 0 commentaire ;
- **Liverpool vs Galatasaray** : 100 articles, 18 posts sociaux, 5 commentaires.

6.3 Analyse des plateformes




FIGURE 6.2 – Distribution des langues détectées dans les articles de presse et les posts sociaux




FIGURE 6.3 – Répartition des articles par source médiatique

Deuxième partie

Traitement Automatique du Langage naturel

7. Contribution TAL : extraction, structuration et classification des événements sportifs

7.1 Rôle de la partie TAL

La partie TAL constitue le cœur technique et scientifique du projet. Son objectif est de transformer des données textuelles issues des réseaux sociaux en informations structurées permettant de reconstruire une chronologie sportive.

7.2 Chargement et exploration des données

L'exploration initiale montre que le corpus brut contient :

- **200 posts** récupérés ;
- **46 416 commentaires** scannés ;
- **1 228 commentaires** associés aux fenêtres du match ;
- un taux de correspondance d'environ 2,65 pour cent.

Ce taux relativement faible montre que la quantité brute de commentaires ne suffit pas. Une grande partie des commentaires collectés n'est pas directement exploitable pour reconstruire la chronologie du match.

7.3 Filtrage des publications pertinentes

Parmi les 200 publications initiales, seules 90 publications sont considérées comme pertinentes pour l'analyse TAL. Ce filtrage permet de conserver les textes liés au match, aux équipes, aux événements sportifs ou aux discussions proches de la rencontre.

7.4 Nettoyage TAL des titres

Avant toute détection d'événements, les titres des publications sont nettoyés. Le nettoyage consiste notamment à convertir les textes en minuscules, supprimer certains caractères spéciaux, normaliser les espaces et conserver les mots utiles pour l'analyse événementielle.

7.5 Détection des événements par règles

La première méthode utilisée pour identifier les événements sportifs repose sur une approche par règles. Cette approche consiste à analyser les titres des publications et à rechercher la présence de certains mots-clés caractéristiques d'un événement sportif.

L'idée générale est simple : lorsqu'un utilisateur publie un message lié à un match, certains mots ou expressions donnent souvent des indices sur la nature de l'événement. Par exemple, un titre contenant les termes *goal*, *scored*, *winner* ou un score comme *1-0* peut indiquer un but. De la même manière, des expressions comme *VAR*, *offside* ou *penalty review* peuvent signaler une décision arbitrale ou une action vérifiée par la vidéo.

Les classes utilisées sont les suivantes :

- **MATCH THREAD** : fil de discussion consacré au match ;
- **FIN MATCH** : discussion ou résumé après le match ;
- **BUT** : titre indiquant un but, un score ou une action décisive ;
- **VAR** : référence à une décision arbitrale, à un hors-jeu ou à une vérification vidéo ;
- **CARTON ROUGE** : référence à une expulsion ou à un carton rouge ;
- **AUTRE** : texte ne correspondant pas clairement à un événement sportif précis.

7.6 Extraction automatique des scores

En plus de la détection du type d'événement, une étape spécifique est consacrée à l'extraction automatique des scores présents dans les titres. Cette étape est importante, car les scores constituent des indices forts dans le contexte sportif.

L'extraction des scores repose sur la recherche de motifs numériques dans les titres nettoyés. Le principe consiste à parcourir chaque titre et à vérifier s'il contient deux nombres séparés par un tiret, deux-points ou un espace autour d'un séparateur.

Les formes recherchées sont par exemple :

- **1-0** ;
- **2-1** ;
- **3-2** ;

- 7-0;
- 1 : 0.

7.7 Construction du tableau final TAL

Après les étapes de nettoyage, de détection des événements et d'extraction des scores, les informations obtenues sont regroupées dans un tableau final TAL. Ce tableau constitue une représentation structurée des publications analysées.

Le tableau final contient **90 lignes** et **8 colonnes**. Il permet de passer d'un ensemble de textes bruts à un jeu de données organisé, exploitable pour la visualisation, la classification automatique et la construction d'une chronologie sociale.

Titre simplifié	Événement détecté	Score	Commentaires	Catégorie temporelle
Liverpool vs Galatasaray Match Thread	MATCH THREAD	–	920	PENDANT MATCH
Post Match Thread Galatasaray Liverpool	FIN MATCH	1-0	388	APRÈS MATCH
Goal ruled out after VAR decision	VAR	–	257	PENDANT MATCH
Red card incident discussed by fans	CARTON ROUGE	–	90	PENDANT MATCH
General discussion about Liverpool form	AUTRE	–	71	APRÈS MATCH

TABLE 7.1 – Exemple simplifié de structuration du tableau final TAL

Ce tableau illustre le rôle central de la partie TAL. Les textes ne sont plus seulement des phrases isolées : ils deviennent des données structurées.

7.8 Distribution initiale des événements détectés

Après l'application des règles de détection sur les 90 publications retenues, une première distribution des événements est obtenue.

- **MATCH THREAD** : 35 occurrences ;
- **AUTRE** : 28 occurrences ;

- **FIN MATCH** : 21 occurrences ;
- **BUT** : 3 occurrences ;
- **VAR** : 2 occurrences ;
- **CARTON ROUGE** : 1 occurrence.

La distribution montre que les catégories **MATCH THREAD**, **AUTRE** et **FIN MATCH** sont les plus représentées. Cela signifie que la majorité des publications correspondent plutôt à des discussions générales, à des fils de match ou à des discussions après la rencontre.

7.9 Construction de la timeline sociale

Après la détection des événements, l'étape suivante consiste à replacer chaque publication dans une chronologie. L'objectif est de construire une **timeline sociale**, c'est-à-dire une représentation temporelle des événements détectés à partir des publications et des réactions des utilisateurs.

Pour cela, la date de publication de chaque post est comparée à l'heure de début du match. Cette comparaison permet de convertir l'heure absolue de publication en une minute relative par rapport au coup d'envoi.

	minute_match	categorie_temps	evenement	titre
0	12369	APRES_MATCH	AUTRE	Looking at the sequence of events around Liver...
1	-52272	AVANT_MATCH	VAR	10 years ago today, Jamie Vardy's volley vs Li...
2	77367	APRES_MATCH	MATCH_THREAD	Match Thread: Manchester United vs Liverpool ...
3	-231778	AVANT_MATCH	FIN_MATCH	Post Match Thread: Galatasaray 1 : Liverpool 0...
4	-1585540	AVANT_MATCH	FIN_MATCH	Post Match Thread: Liverpool 7 - 0 Manchester ...
5	77546	APRES_MATCH	FIN_MATCH	Post Match Thread: Manchester United 3-2 Liver...

FIGURE 7.1 – Timeline sociale complète des événements détectés

Cette représentation permet de visualiser la dispersion temporelle des contenus et d'observer si les publications se concentrent autour de la période réelle du match.

7.10 Filtrage temporel de la timeline

Après la construction de la timeline sociale complète, une étape de filtrage temporel est nécessaire. En effet, toutes les publications qui mentionnent Liverpool ou Galatasaray ne correspondent pas forcément au match étudié.

L'objectif du filtrage temporel est donc de conserver uniquement les publications situées dans une fenêtre temporelle proche du match. Cette étape permet d'améliorer

la qualité de la chronologie sociale en éliminant les contenus trop éloignés du coup d'envoi.

9] :

evenement	AUTRE	BUT	CARTON_ROUGE	FIN_MATCH	MATCH_THREAD	VAR
categorie_temps						
APRES_MATCH	6	0	0	2	17	0
AVANT_MATCH	21	3	1	19	18	2
PENDANT_MATCH	1	0	0	0	0	0

FIGURE 7.2 – Timeline sociale après filtrage temporel

Le filtrage temporel permet de passer d'une timeline sociale large et bruitée à une timeline plus précise, plus proche du déroulement réel du match.

7.11 Activité sociale associée aux événements

La partie TAL relie aussi les événements détectés au volume d'activité sociale, notamment au nombre de commentaires associés aux publications.

7.12 Vectorisation TF-IDF

Après l'approche par règles, une approche statistique est introduite avec la vectorisation TF-IDF. Dans cette expérimentation, les 90 titres sont vectorisés. La matrice TF-IDF obtenue contient 90 lignes et 346 colonnes.

7.13 Classification supervisée des événements

Un modèle de régression logistique est entraîné pour prédire automatiquement la classe d'un titre à partir de sa représentation TF-IDF. Les données sont séparées en 72 exemples pour l'apprentissage et 18 exemples pour le test.

Une première version du modèle obtient une accuracy de 0.889.

7.14 Amélioration des règles et des labels

L'analyse des erreurs révèle plusieurs limites dans les règles initiales. Le système pouvait détecter à tort la chaîne *var* à l'intérieur d'autres mots, comme *Vardy*. Cette erreur a conduit à améliorer les règles.

7.15 Comparaison des versions du modèle

La première version obtient une accuracy de 0.889. La deuxième version obtient une accuracy de 0.833. La troisième version obtient une accuracy de 0.778.

La distribution finale des labels est la suivante :

- **MATCH THREAD** : 37 occurrences ;
- **AUTRE** : 29 occurrences ;
- **FIN MATCH** : 19 occurrences ;
- **BUT** : 3 occurrences ;
- **VAR** : 1 occurrence ;
- **CARTON ROUGE** : 1 occurrence.

7.16 Analyse de sentiment appliquée aux titres

Une première analyse de sentiment est appliquée aux 90 titres du fichier TAL. Les résultats sont les suivants :

- **79 titres positifs** ;
- **11 titres négatifs**.




FIGURE 7.3 – Répartition du sentiment sur les titres analysés

7.17 Analyse de sentiment appliquée aux commentaires

L'analyse est ensuite appliquée aux commentaires extraits du fichier JSON. Au total, 1 228 commentaires sont récupérés.

Les résultats obtenus sont :

- **873 commentaires négatifs ;**
- **355 commentaires positifs.**

En proportion, cela correspond à environ 71,1 pour cent de commentaires négatifs et 28,9 pour cent de commentaires positifs.




FIGURE 7.4 – Répartition du sentiment sur les commentaires Reddit

7.18 Limites de la contribution TAL

Le nombre de titres reste limité, les classes sont très déséquilibrées et les règles linguistiques restent sensibles aux formulations ambiguës. Les commentaires Reddit contiennent aussi de l'ironie, des abréviations et du langage communautaire.

7.19 Apport global de la contribution TAL

La contribution TAL apporte une valeur centrale au projet. Elle permet de transformer des textes sociaux en données structurées, d'extraire des événements, de construire une timeline sociale et d'ajouter une dimension émotionnelle.

Troisième partie

Analyse de sentiment et détection automatique d'événements

8. Analyse de sentiment et détection automatique d'événements

8.1 Comparaison des timelines

L'analyse temporelle des événements d'un match de football peut être abordée selon différents points de vue : officiel, social et médiatique.

8.1.1 Timeline officielle

La timeline officielle décrit les événements réels du match : buts, cartons, décisions VAR, changements importants et fin de la rencontre.

8.1.2 Timeline sociale

La timeline sociale est construite à partir des commentaires Reddit. Elle reflète la perception du public.

8.1.3 Timeline médiatique

La timeline médiatique est construite à partir des articles de presse. Elle est généralement plus structurée, mais moins immédiate.

8.2 Événements du match Galatasaray vs Liverpool et impact émotionnel

L'analyse de sentiment sur ce match permet de mettre en relation les événements réels avec les réactions observées dans les commentaires Reddit.

Temps	Événement	Impact émotionnel attendu et observé
8e	But d'Osimhen	Positif pour Galatasaray, négatif pour Liverpool. Augmentation attendue des réactions selon l'affiliation des supporters.
35e	But annulé après VAR	Frustration pour Galatasaray, soulagement pour Liverpool. Pic probable de commentaires négatifs et de mentions liées à la VAR.
55e	Carton jaune de Sanchez	Frustration modérée. Impact moins intense qu'un but ou une décision VAR.
72e	Carton jaune de Szoboszlai	Frustration pour Liverpool. Impact émotionnel généralement plus faible qu'un but.
90e	Fin du match	Euphorie pour Galatasaray, déception pour Liverpool. Pic de réactions après la rencontre.

TABLE 8.1 – Événements clés du match Galatasaray vs Liverpool et impacts émotionnels attendus

8.3 Objectif de l'analyse de sentiment

L'analyse de sentiment vise à mesurer l'évolution émotionnelle des réactions sociales pendant le match. L'idée est que les événements importants ne modifient pas seulement le volume des commentaires, mais aussi leur tonalité émotionnelle.




FIGURE 8.1 – Répartition globale des sentiments dans les commentaires Reddit

Dans l’analyse réalisée, on observe que :

- les fenêtres autour du but annulé après VAR présentent une valence moyenne particulièrement négative ;
- le but d’Osimhen génère un pic de volume de commentaires ;
- les cartons jaunes produisent des variations plus faibles ;
- la fin du match génère un afflux de commentaires dans le fil de discussion d’après-match.




FIGURE 8.2 – Comparaison de la répartition des sentiments par match

8.4 Modèle utilisé

Le modèle `cardiffnlp/twitter-roberta-base-sentiment-latest` est utilisé. Il s'agit d'un modèle RoBERTa entraîné sur des textes courts issus de Twitter. Ce choix est pertinent car les commentaires sportifs sur les réseaux sociaux sont courts, spontanés et souvent émotionnels.

Le modèle classe les textes en trois catégories :

- sentiment négatif;
- sentiment neutre;
- sentiment positif.




FIGURE 8.3 – Évolution de la valence moyenne et des fractions de sentiments positifs et négatifs au cours du match

8.5 Agrégation temporelle

Les commentaires sont regroupés par fenêtres de cinq minutes. Pour chaque fenêtre, plusieurs variables sont calculées : nombre de commentaires, score moyen, valence moyenne, proportion de commentaires négatifs, variations temporelles et moyennes glissantes.

8.6 Classification des fenêtres événementielles

À partir des signaux temporels, trois modèles de classification sont comparés :

- **Régression logistique** : F1-macro moyen égal à 0.433, ROC-AUC moyen égal à 0.750;
- **Forêt aléatoire** : F1-macro moyen égal à 0.583, ROC-AUC moyen égal à 0.650;
- **Gradient boosting** : F1-macro moyen égal à 0.720, ROC-AUC moyen égal à 0.825.

Le modèle Gradient Boosting obtient les meilleurs résultats moyens.

8.7 Visualisation de la détection d'événements

La figure suivante présente la superposition des prédictions du modèle Gradient Boosting sur la chronologie du match, comparée aux événements réels.




FIGURE 8.4 – Probabilité d'événement prédite par le modèle et événements réels

On observe que les pics de probabilité prédite coïncident souvent avec les événements réels. Ces pics s'accompagnent généralement d'une valence négative plus marquée, ce qui confirme l'hypothèse selon laquelle les événements sportifs importants génèrent des réactions émotionnelles détectables dans les commentaires.

9. Discussion générale

9.1 Forces du projet

Le projet combine plusieurs sources de données : Reddit, médias et fichiers officiels de match. Il propose une chaîne de traitement complète : collecte, nettoyage, structuration, analyse temporelle, TAL, analyse de sentiment et comparaison.

9.2 Limites

Les principales limites concernent la qualité des données, le déséquilibre entre les plateformes, la taille réduite de certaines données exploitables et les limites des modèles de détection de sentiment.

9.3 Perspectives

Plusieurs améliorations peuvent être envisagées : enrichir le corpus avec davantage de matchs, améliorer la collecte Reddit, utiliser des modèles multilingues et entraîner un modèle supervisé de détection d'événements.

9.4 Accès au code source et aux fichiers du projet

L'ensemble des fichiers utilisés dans le cadre de ce projet, ainsi que le code source permettant de reproduire les principales étapes de traitement, sont disponibles dans le dépôt GitHub suivant :

Dépôt GitHub du projet

Ce dépôt regroupe les scripts, les notebooks, les données de travail et les éléments nécessaires à la reproduction des analyses réalisées dans ce rapport.

10. Conclusion

Ce projet montre qu'il est possible de reconstruire et de comparer des chronologies d'événements sportifs à partir de données issues des réseaux sociaux et des médias numériques. Les réactions sociales constituent une source rapide, émotionnelle et proche du déroulement du match, tandis que les médias offrent une vision plus structurée et analytique.

La contribution principale du projet réside dans la transformation d'un ensemble de données sociales et médiatiques non structurées en une représentation temporelle organisée, interprétable et comparable.